EV Challenge — Sprint 04
GoodWeAI · EV ChargeOps Assistant

Relatório de evolução do projeto

Ciência da Computação — 2º semestre · Turma 1CCPK · 2026.2

O projeto evoluiu do protótipo das Sprints 1/2 e da arquitetura conversacional LCEL da Sprint 3 para um RAG local medido: ChromaDB persistente, embeddings nomic, citações verificadas, duas versões de prompt, avaliação RAGAS e interface Streamlit.

Entrega	Evidência
Interface web	Streamlit: login, chat e painel administrativo
RAG reproduzível	data/knowledge_base + preparar_rag_sprint4.cmd
Avaliação	13 casos, 2 iterações e arquivo bruto versionado
Relatórios	relatorio_rag.md e relatorio_modelos.md

Execução totalmente local com PostgreSQL, ChromaDB e Ollama. Credenciais permanecem no arquivo .env ignorado pelo Git.

1. Pipeline RAG e decisões técnicas

Fluxo: documentos versionados → validação do manifesto → chunking → embeddings nomic-embed-text → ChromaDB persistente → filtro por perfil → top-k → prompt LCEL → Llama 3.2 → validação das citações.

Decisão	Configuração	Trade-off
Chunking	900 caracteres, overlap 150	Simples e determinístico; com o corpus curto atual resultou em 1 trecho por documento.
Recuperação	v1 k=2; v2 k=4	v2 aumenta contexto e tokens, mas elevou recall e métricas.
Índice	Nome derivado do hash	Reprodutível e preserva índices anteriores; usa espaço adicional.
Embedding	nomic-embed-text local	Privacidade e operação offline após instalação; exige Ollama e 274 MB.
Perfis	Filtro antes da geração	Reduz exposição; depende de metadados corretos no manifesto.

Base: cinco documentos acadêmicos herdados, FAQ, tabela tarifária explicitamente fictícia e uma síntese referenciada do manual GoodWe HCA. Não foi atribuída documentação ChargeGrid inexistente à GoodWe.

Guardrails: conteúdo recuperado é dado, não instrução; padrões de injection documental são descartados; resposta sem fonte recuperada é substituída por recusa; especificações ausentes não podem ser inventadas.

2. Avaliação RAGAS e evolução do prompt

Execução local de 21/10/2026. O eval set foi fixado antes da medição, com 13 perguntas e referências. O Qwen 3:4b atuou como julgador RAGAS; isso mantém o ensaio local, mas é uma fonte possível de viés.

Versão	Mudança principal	k	Faithfulness	Relevância	Recall fonte	Citação
v1	Grounding e fonte básica	2	0,705	0,428	0,846	46,2%
v2	Cobertura, recusa e fonte por parágrafo	4	0,876	0,654	1,000	92,3%
Ganho	v2 – v1	+2	+0,171	+0,226	+0,154	+46,1 p.p.

Cada média usa as 13 respostas válidas do Llama em cada versão. A v2 teve ganho nas duas métricas obrigatórias. Prompt e k mudaram simultaneamente; por isso o resultado comprova melhoria do pipeline, não causalidade isolada de uma única alteração.

Comparação de modelos: o Llama concluiu 26/26 tentativas (100%, latência válida média 1,31 s). O Qwen concluiu 1/26 (3,8%, 4,80 s); nas demais, atingiu max_tokens=512 durante raciocínio. As falhas foram preservadas, sem notas inventadas. Parâmetros comuns: temperature 0, top_p 0,9, num_ctx 8192, seed 42.

Evidência auditável: evals/sprint4/results.json contém configurações, hashes, trechos, respostas, tokens, tempos, notas e saídas do julgador.

3. Comparativo antes/depois

Critério	Sprints 1/2 — versão original	Sprint 4 — RAG avaliado
Embeddings	Sem avaliação nomic reproduzível	nomic-embed-text local
Índice	Busca inicial sem artefato medido	ChromaDB persistente por hash
Scores	Não medidos; N/D	v1: 0,705/0,428; v2: 0,876/0,654
Contexto	Base inicial e recuperação sem recall registrado	Recall da fonte: 0,846 → 1,000
Citações	Não exigidas/medidas	46,2% → 92,3%; validação contra fontes recuperadas
Segurança	Guardrails conversacionais básicos	Recusa sem contexto e injection documental
Interface	Protótipo web	Streamlit com tema, perfis e administração
Reprodutibilidade	Sem snapshot completo de avaliação	Corpus, prompts, dataset, hashes e resultado bruto

Problema 1 — respostas sem fonte. Solução: IDs estáveis no contexto e pós-validação; resposta sem citação válida vira recusa. Motivo: impedir que uma frase fluente pareça comprovada sem evidência.

Problema 2 — Qwen truncava respostas. Decisão: manter a falha no comparativo e selecionar Llama, que concluiu 100%. Motivo: aumentar o limite depois da execução mudaria a configuração e invalidaria a comparação fixada.

Problema 3 — documentos curtos geraram poucos chunks. Decisão: registrar a limitação e manter chunking parametrizado para crescimento do corpus, sem inflar artificialmente os documentos.

4. Equipe, entrega e limitações

A tabela mantém a divisão de responsabilidades planejada na Sprint anterior. Ela não substitui a confirmação das contribuições efetivamente realizadas nem o histórico Git.

Integrante / RM	Responsabilidade principal prevista
Rodger Costa Rios · 571438	Coordenação, integração da arquitetura e LCEL
Felipe Pereira Restivo · 570712	Interface e experiência de uso no Streamlit
Gabriel Rodrigues Zappelloni · 572060	RAG, ChromaDB e base de conhecimento
Kenichi Caio Yamamoto · 569815	PostgreSQL, modelos e persistência de sessões
Maykon de Lima Silva · 574022	Guardrails, evals, modelos e documentação

Limitações: corpus acadêmico pequeno; uma síntese HCA, não manual ChargeGrid; tarifa de demonstração não é preço real; julgador e modelo comparado compartilham a família Qwen; execução depende dos modelos Ollama previamente instalados.

Checklist: PDF com 5 páginas; relatorios RAG/modelos; interface; corpus; prompts v1/v2; resultados brutos; arquivo TXT; .env ignorado. Antes do envio, o grupo deve revisar este documento, confirmar contribuições reais, verificar o repositório público e conferir o histórico quanto a segredos.

Uso de IA generativa: houve auxílio no desenvolvimento, revisão técnica e documentação. O grupo permanece responsável por compreender, validar e apresentar a solução.

Repositório: https://github.com/rodgercr/ev-chargeops-assistant/tree/sprint-3